МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ ФЕДЕРАЦИИ

Национальный исследовательский ядерный университет «МИФИ»

Кафедра интеллектуальных систем

КУРСОВАЯ РАБОТА

по дисциплине «Классическое машинное обучение»

ТЕМА:

Прогнозирование эффективности химических соединений против вируса гриппа методами машинного обучения

Москва — 2026

Оглавление

ВВЕДЕНИЕ 3
1 ОПИСАНИЕ ДАННЫХ И ПОСТАНОВКА ЗАДАЧИ 4
2 РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ 6
2.1 Распределения целевых переменных 6
2.2 Корреляционный анализ 7
2.3 Анализ признаков 8
3 РЕГРЕССИОННЫЕ МОДЕЛИ 10
3.1 Регрессия IC50 10
3.2 Регрессия CC50 12
3.3 Регрессия SI 13
4 КЛАССИФИКАЦИОННЫЕ МОДЕЛИ 15
4.1 Классификация IC50 > медианы 15
4.2 Классификация CC50 > медианы 16
4.3 Классификация SI > медианы 17
4.4 Классификация SI > 8 18
5 СРАВНЕНИЕ РЕЗУЛЬТАТОВ 20
ЗАКЛЮЧЕНИЕ 22

ВВЕДЕНИЕ

Разработка новых лекарственных препаратов является одним из наиболее ресурсоёмких направлений современной науки. Традиционный путь от синтеза соединения до его вывода на рынок занимает в среднем 10–15 лет и требует значительных финансовых затрат. Методы машинного обучения позволяют существенно сократить этот путь за счёт компьютерного предсказания биологической активности соединений ещё до их синтеза.

Ключевыми показателями эффективности противовирусных соединений являются IC50 (концентрация 50%-го ингибирования вируса), CC50 (цитотоксическая концентрация для 50% клеток) и SI (индекс селективности, равный отношению CC50 к IC50). Высокое значение SI свидетельствует о том, что соединение активно против вируса при минимальном вреде для клеток хозяина. Согласно принятым в фармакологии стандартам, значение SI > 8 считается клинически значимым и достаточным для перевода соединения в следующую фазу разработки.

Цель работы — построить и сравнить модели машинного обучения для предсказания указанных показателей на основе 210 молекулярных дескрипторов 1001 химического соединения. В рамках работы решаются задачи как регрессии (предсказание числовых значений IC50, CC50, SI), так и классификации (превышает ли значение медиану или клинически значимый порог SI > 8).

Структура работы: раздел 1 описывает данные и постановку задач; раздел 2 — разведочный анализ; разделы 3 и 4 — построенные модели; раздел 5 — итоговое сравнение. В заключении сформулированы выводы и рекомендации.

1 ОПИСАНИЕ ДАННЫХ И ПОСТАНОВКА ЗАДАЧИ

Исходный датасет содержит сведения о 1001 химическом соединении. Каждое соединение описывается 210 числовыми молекулярными дескрипторами, вычисленными с помощью библиотеки RDKit, и тремя целевыми переменными. Пропущенных значений в целевых переменных нет; часть дескрипторов содержала пропуски, заполненные медианой соответствующего столбца.

Таблица 1 — Описание целевых переменных

Переменная	Полное название	Химический смысл	Ед.
IC50	Half Maximal Inhibitory Concentration	Концентрация 50%-го ингибирования вируса. Чем меньше — тем активнее соединение	мМ
CC50	Cytotoxic Concentration 50%	Концентрация, токсичная для 50% клеток хозяина. Чем больше — тем безопаснее	мМ
SI	Selectivity Index = CC50/IC50	Индекс селективности. SI > 8 — клинически значимый порог	б/р

Таблица 2 — Основные статистики целевых переменных

Показатель	IC50, мМ	CC50, мМ	SI
Кол-во наблюдений	1001	1001	1001
Минимум	0,004	0,031	0,011
25-й перцентиль	12,5	100,2	1,43
Медиана	46,6	411,0	3,85
Среднее	222,8	1 217,4	72,5
75-й перцентиль	225,0	1 723,6	16,6
Максимум	4 128,5	37 082,4	15 620,6
Стд. отклонение	402,2	3 071,3	684,5

Все три переменных имеют сильно правостороннее (right-skewed) распределение, что обусловливает необходимость логарифмической трансформации log1p(x) перед обучением регрессионных моделей. Связь SI

= CC50 / IC50 подтверждена аналитически: при совместном использовании IC50 и CC50 как признаков для предсказания SI возникает утечка данных, поэтому в задаче регрессии SI они исключались.

В работе решается семь задач машинного обучения:

- регрессия IC50 — предсказание числового значения на логарифмической шкале;
- регрессия CC50 — предсказание числового значения на логарифмической шкале;
- регрессия SI — без использования IC50 и CC50 как признаков;
- классификация IC50 > медианы (46,6 мМ) — бинарная, сбалансированная;
- классификация CC50 > медианы (411,0 мМ) — бинарная, сбалансированная;
- классификация SI > медианы (3,85) — бинарная, сбалансированная;
- классификация SI > 8 — бинарная, несбалансированная (35,7% / 64,3%).

2 РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ

Разведочный анализ данных (EDA) проведён с применением статистических методов и визуальных инструментов библиотек matplotlib и seaborn. Признаки с нулевой дисперсией (18 штук) удалены: после фильтрации осталось 192 признака.

2.1 Распределения целевых переменных

На рисунке 1 представлены гистограммы исходных и log1p-преобразованных значений IC50, CC50 и SI. Все три переменных демонстрируют экспоненциальный хвост. После логарифмирования распределения приближаются к нормальному, что позволяет применять стандартные регрессионные методы.

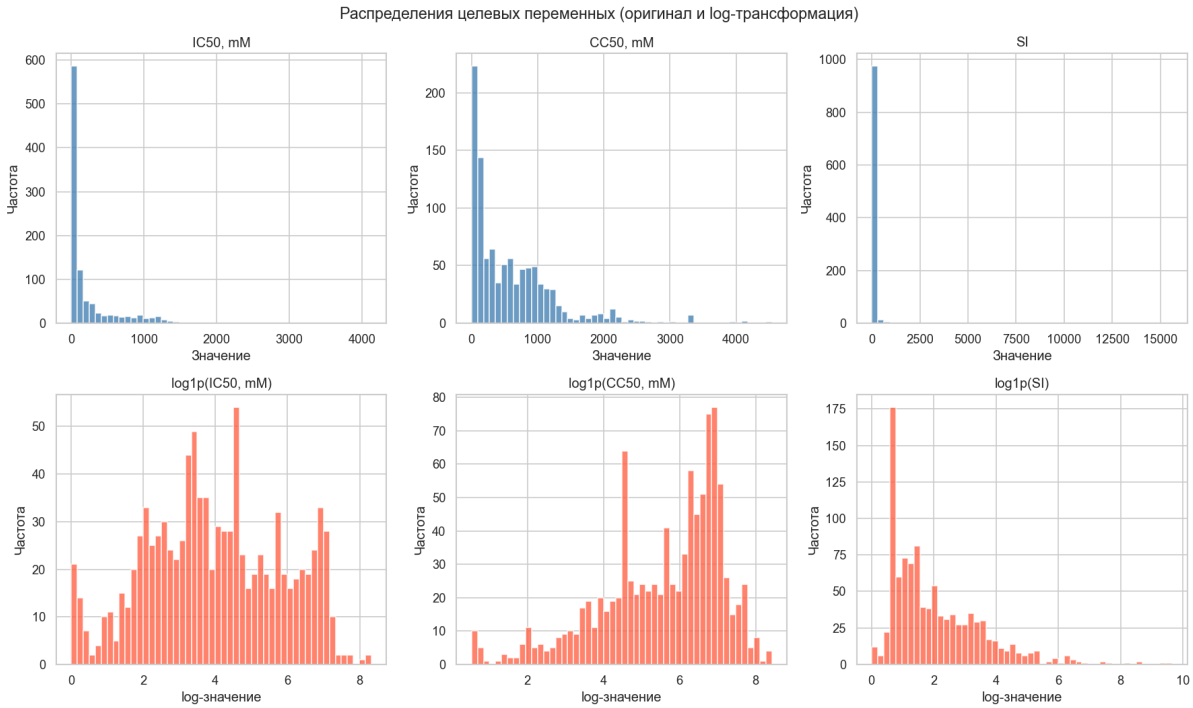

Рисунок 1 — Распределения IC50, CC50, SI (оригинал и log1p-трансформация)

Боксплоты в логарифмической шкале (рисунок 2) показывают разброс и выбросы. Для SI зафиксировано 125 выбросов по IQR-критерию (12,5%), для IC50 — 147 (14,7%), для CC50 — 39 (3,9%). Выбросы не удалялись, поскольку аномально высокие значения SI могут соответствовать реально высокоселективным кандидатам.

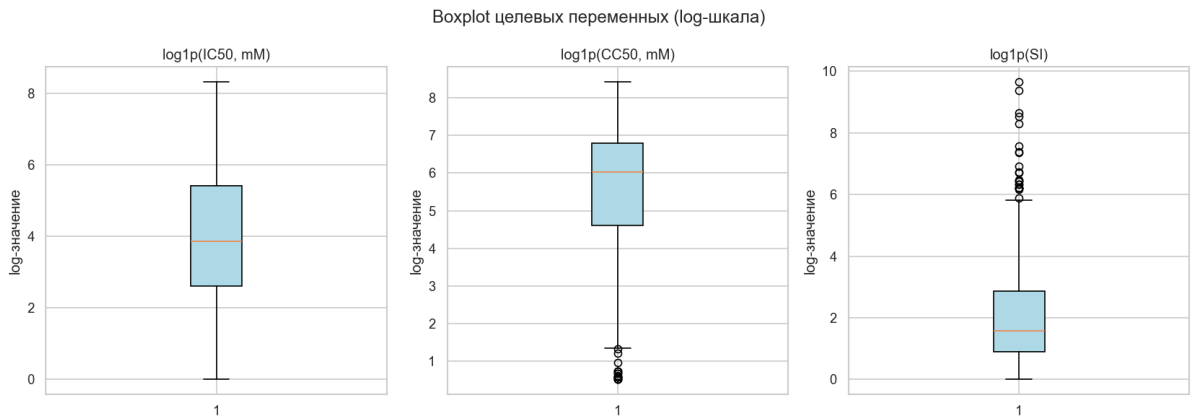

Рисунок 2 — Боксплоты целевых переменных в log-шкале

2.2 Корреляционный анализ

Матрица корреляций целевых переменных (рисунок 3) показывает умеренную связь IC50 и CC50 (r = 0,521). SI практически независим от обоих (r = −0,057 и −0,007 соответственно), что объясняется нелинейностью операции деления SI = CC50/IC50.

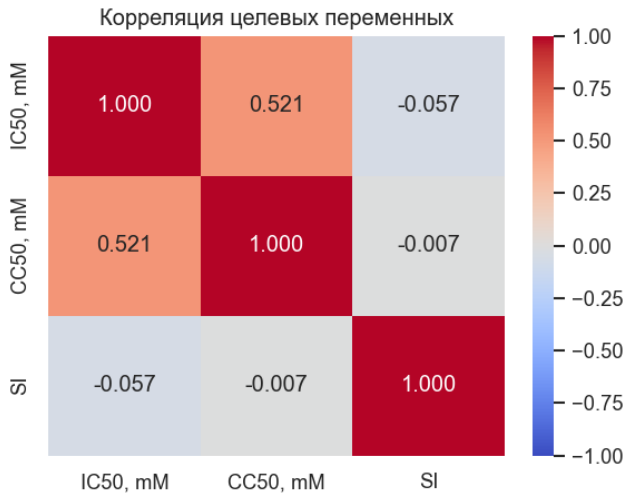

Рисунок 3 — Матрица корреляций целевых переменных

Парный график (рисунок 4) подтверждает слабую линейную зависимость между таргетами в исходной шкале. В log-шкале CC50 и IC50 демонстрируют отчётливую положительную связь, тогда как SI образует облако рассеяния.

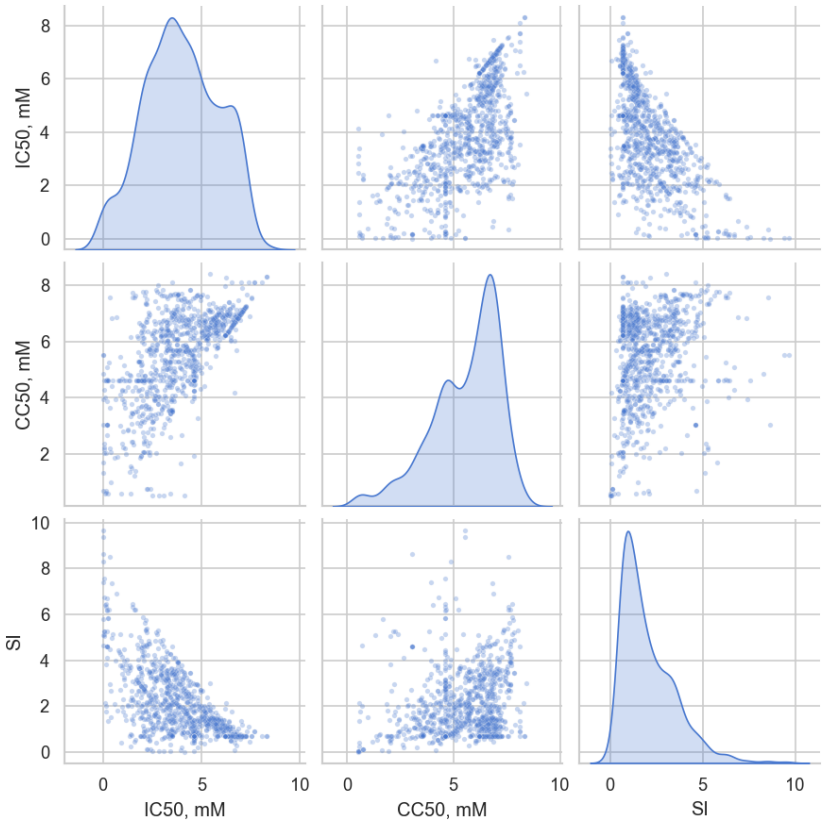

Рисунок 4 — Парные зависимости log1p-преобразованных целевых переменных

2.3 Анализ признаков

Топ-3 признака по модулю корреляции с IC50: VSA_EState4 (r = −0,274), Chi2n (r = −0,257), PEOE_VSA7 (r = −0,256). Все коэффициенты умеренные, что указывает на преимущественно нелинейный характер зависимостей.

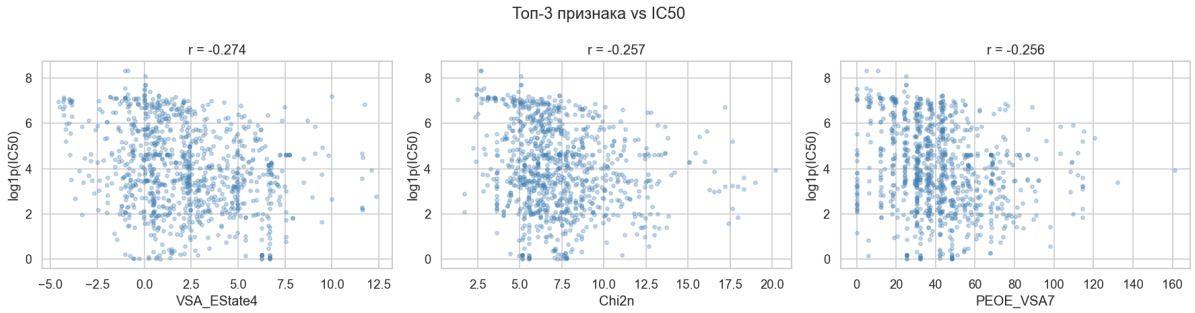

Рисунок 5 — Scatter-диаграммы топ-3 признаков относительно log1p(IC50)

Тепловая карта корреляций топ-20 признаков (рисунок 6) выявляет несколько кластеров мультиколлинеарных дескрипторов: группы Chi* (топологические индексы связности), VSA_EState* (дескрипторы электронного состояния и площади поверхности) и BCUT2D_*

(дескрипторы Бёрси–Крауса). Наличие кластеров объясняется химической близостью описываемых молекулярных свойств.

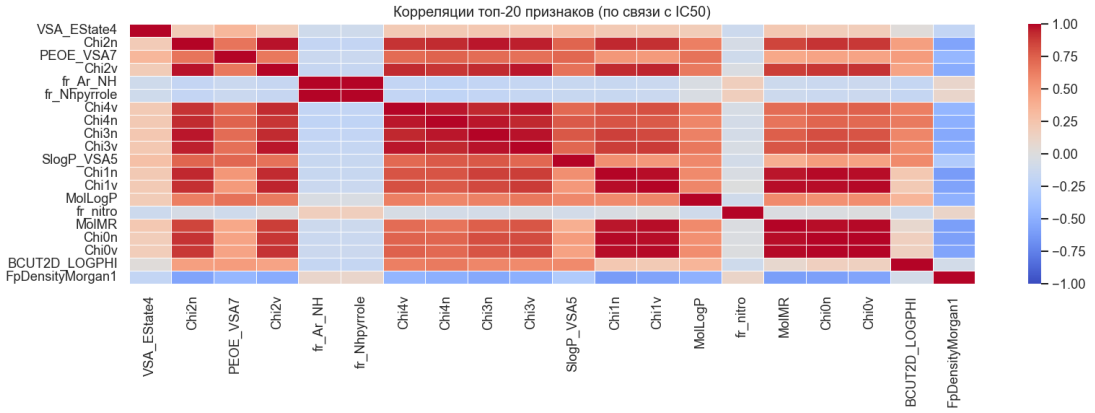

Рисунок 6 — Тепловая карта корреляций топ-20 признаков

3 РЕГРЕССИОННЫЕ МОДЕЛИ

Для всех трёх задач регрессии применялась единая методология: логарифмическая трансформация таргета (log1p), 5-кратная кросс-валидация (KFold, shuffle=True, random_state=42), оценка по метрикам RMSE и R^2. Сравнивались линейные модели (Ridge, Lasso, ElasticNet) и ансамблевые (RandomForest, GradientBoosting). Подбор гиперпараметров проводился методом GridSearchCV.

3.1 Регрессия IC50

Линейные модели показывают слабое качество: Ridge с параметрами по умолчанию имеет CV $R^2 = -0{,}76$, то есть работает хуже предсказания константой. Lasso с alpha = 0,1 даёт RMSE = 1,66 — наилучший результат среди линейных методов. RandomForest с оптимальными параметрами (max_depth=10, min_samples_split=5, n_estimators=200) достигает минимального CV RMSE = 1,40.

Таблица 3 — Сравнение моделей для задачи регрессии IC50

Модель	RMSE (базов.)	RMSE (tuned)	Лучшие параметры
Ridge	2,2123	1,9105	alpha=500
Lasso	1,8596	1,6566	alpha=0,1
ElasticNet	1,8567	—	по умолч.
RandomForest	1,4199	1,4028	depth=10, split=5, n=200
GradientBoosting	1,4272	1,4210	lr=0,05, depth=3, n=200

График «Факт vs Предсказание» (рисунок 7) демонстрирует $R^2 = 0{,}811$ на обучающей выборке для RandomForest — признак умеренного переобучения. CV-оценка RMSE = 1,40 является более объективным показателем качества модели.

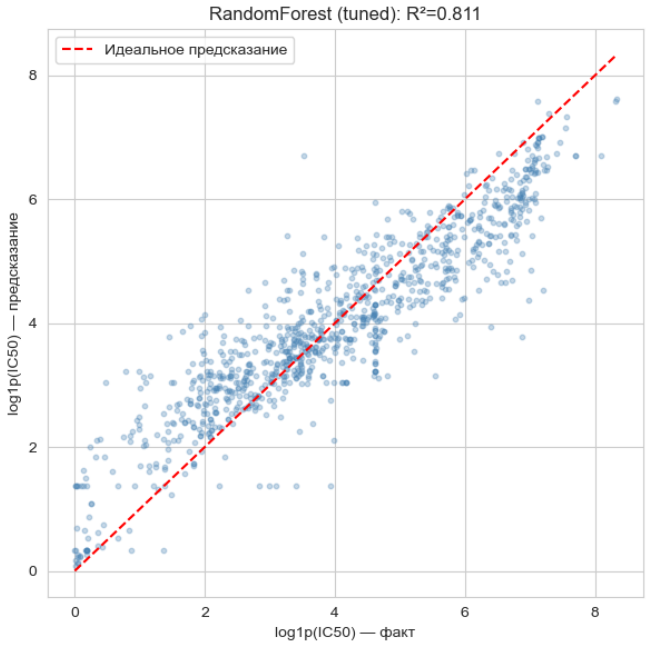

Рисунок 7 — RandomForest: предсказанные vs фактические значения log1p(IC50)

Анализ важности признаков (рисунок 8) показывает, что наиболее информативными для IC50 являются VSA_EState8, VSA_EState4, VSA_EState6 и MolLogP. Данные дескрипторы описывают электронную плотность на поверхности молекулы и её липофильность — ключевые свойства для проникновения через клеточные мембраны к вирусной мишени.

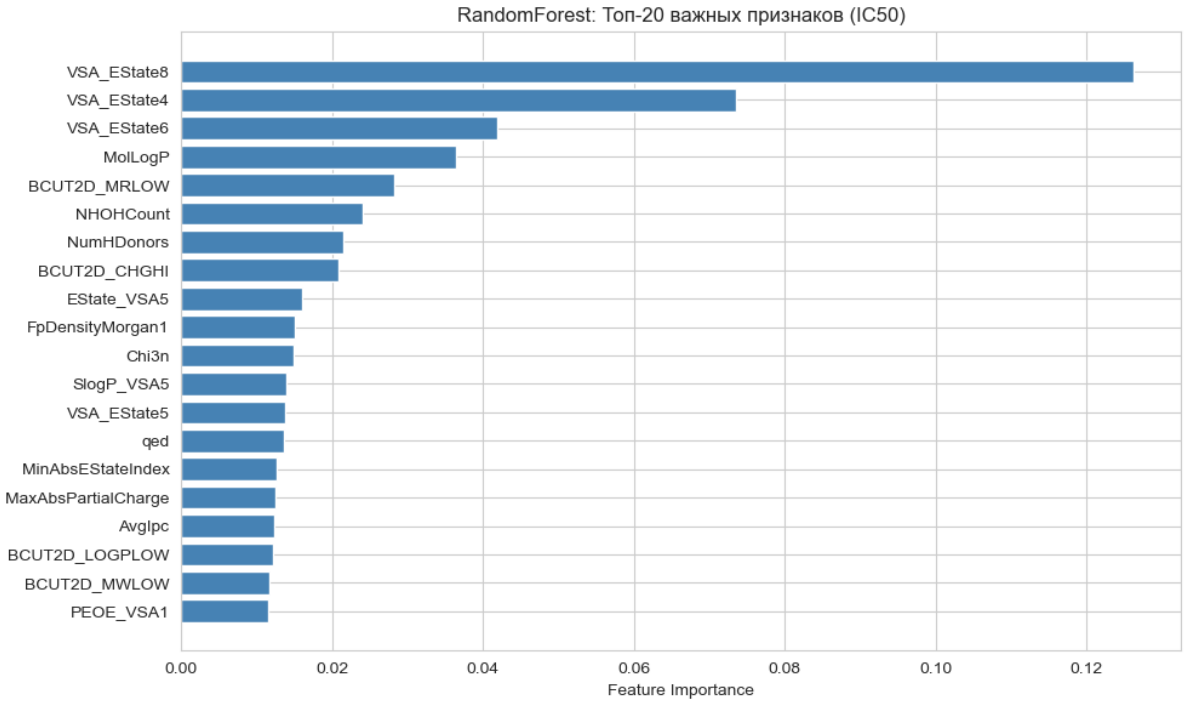

Рисунок 8 — RandomForest: важность признаков для IC50 (топ-20)

3.2 Регрессия CC50

Для CC50 лучшей моделью также оказался RandomForest (CV RMSE = 1,1985), незначительно превосходящий GradientBoosting (CV RMSE = 1,2106). На графике предсказаний (рисунок 9) R^2 = 0,708 на трейне — приемлемый результат для биологических данных.

Таблица 4 — Сравнение моделей для задачи регрессии CC50

Модель	RMSE (tuned)	Лучшие параметры
Ridge	1,7153	alpha=500
Lasso	1,3672	alpha=0,1
RandomForest	1,1985	depth=None, split=5, n=200
GradientBoosting	1,2106	lr=0,05, depth=3, n=200

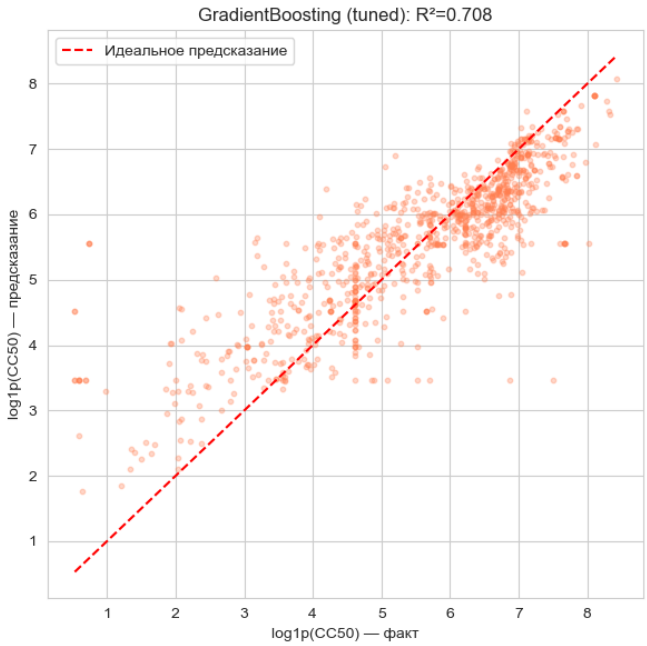

Рисунок 9 — GradientBoosting: предсказанные vs фактические значения log1p(CC50)

Важность признаков для CC50 (рисунок 10) существенно отличается от IC50: топ-признаком является NHOHCount (количество OH и NH групп), за ним следуют BCUT2D_MWLOW, BCUT2D_MRLOW, Kappa1, MolLogP. Доминирование полярных дескрипторов объясняется тем, что цитотоксичность определяется главным образом взаимодействиями с водородными связями.

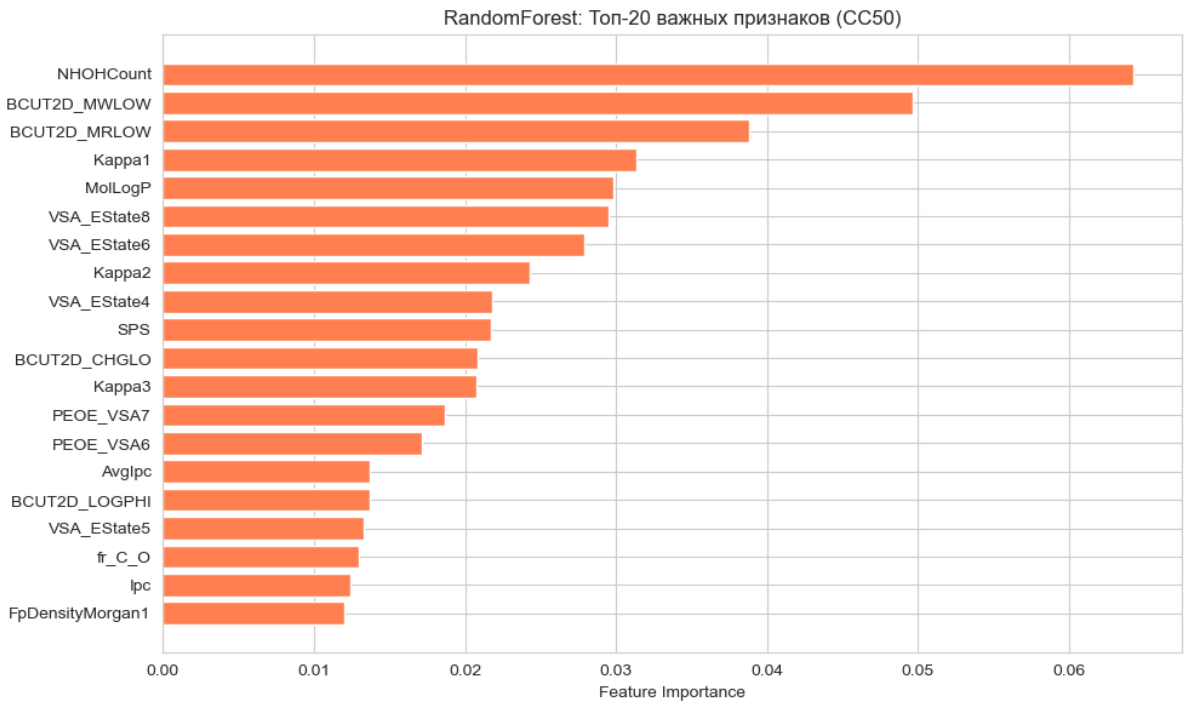

Рисунок 10 — RandomForest: важность признаков для CC50 (топ-20)

3.3 Регрессия SI

SI = CC50/IC50 является наиболее сложной переменной для предсказания, так как представляет отношение двух случайных величин. Признаки IC50 и CC50 исключены во избежание утечки данных. RandomForest (CV RMSE = 1,1720) — лучшая модель. На графике (рисунок 11) R^2 = 0,669: при малых значениях SI наблюдается систематическое завышение предсказаний вследствие регрессии к среднему.

Таблица 5 — Сравнение моделей для задачи регрессии SI

Модель	RMSE (tuned)	Лучшие параметры
Ridge	1,3251	alpha=100
ElasticNet	1,3176	alpha=0,1, l1=0,2
RandomForest	1,1720	depth=10, split=5, n=100
GradientBoosting	1,1958	lr=0,05, depth=5, n=100

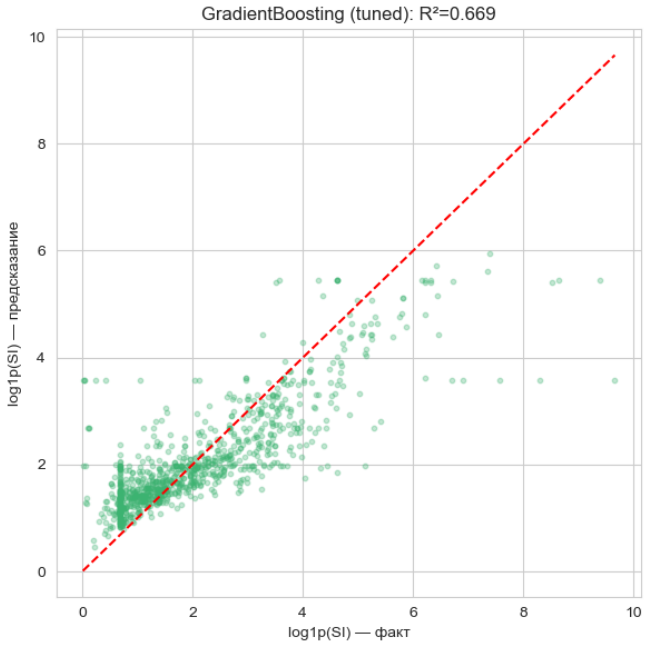

Рисунок 11 — GradientBoosting: предсказанные vs фактические значения log1p(SI)

Среди важных признаков для SI (рисунок 12) выделяются VSA_EState6 и VSA_EState8 (общие с IC50), а также qed (оценка лекарствоподобности по Липинскому) и FractionCSP3 (доля sp3-гибридизованных атомов углерода). Присутствие qed специфично для SI и отражает интегральную «лекарствоподобность» молекулы.

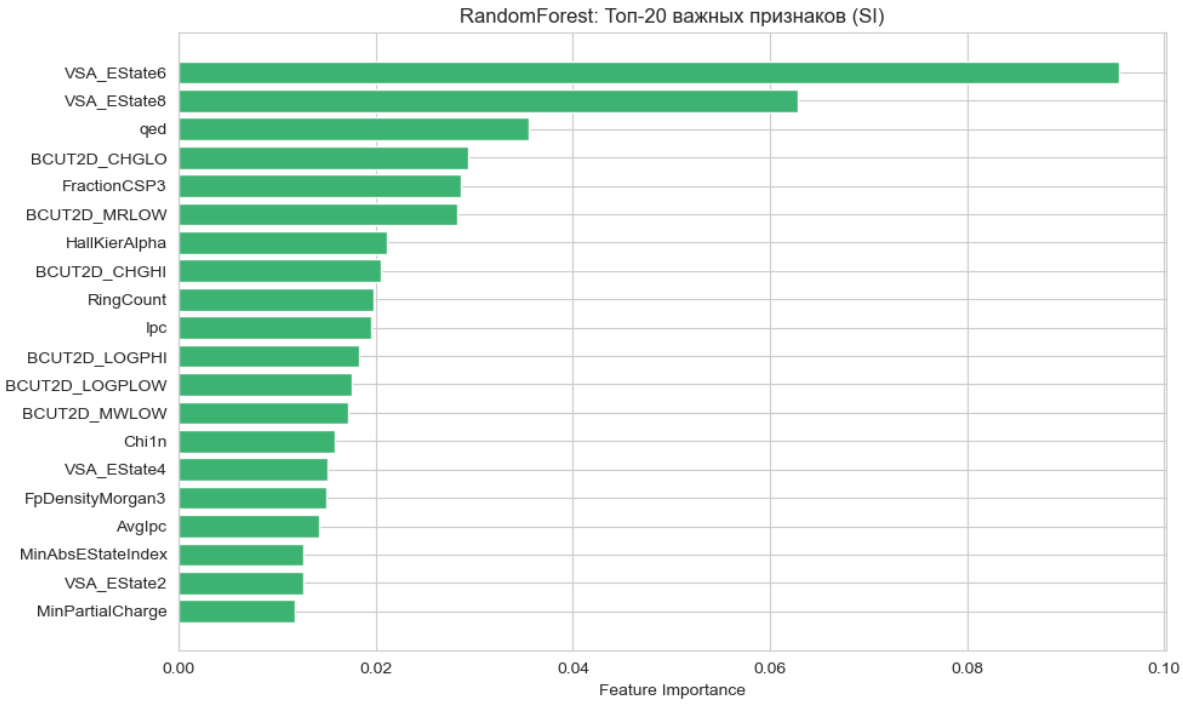

Рисунок 12 — RandomForest: важность признаков для SI (топ-20)

4 КЛАССИФИКАЦИОННЫЕ МОДЕЛИ

Для задач классификации применялась стратифицированная 5-кратная кросс-валидация (StratifiedKFold). Основная метрика — ROC-AUC, устойчивая к дисбалансу. Тестировались: LogisticRegression, SVM (RBF-ядро), RandomForestClassifier, GradientBoostingClassifier.

4.1 Классификация IC50 > медианы

Задача сбалансирована: 500 против 501 образца (50/50). GradientBoosting с lr=0,05, max_depth=3 показал наилучший CV ROC-AUC = 0,7946. На ROC-кривой полного датасета (рисунок 13) RandomForest достигает AUC = 0,98 — признак переобучения на трейне. Честная CV-оценка RandomForest — 0,7857.

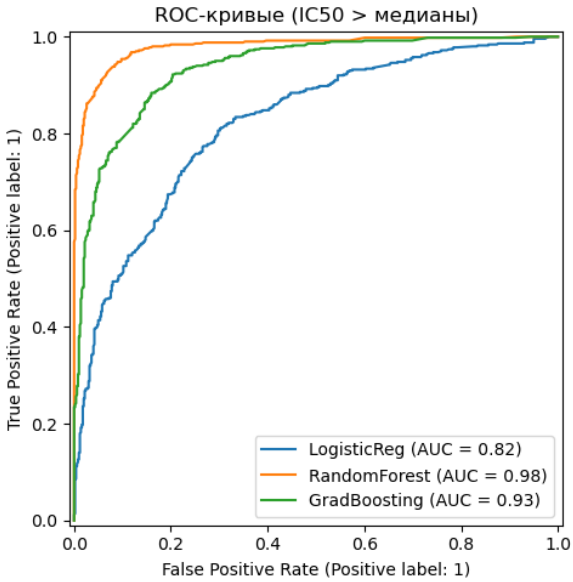

Рисунок 13 — ROC-кривые для задачи IC50 > медианы

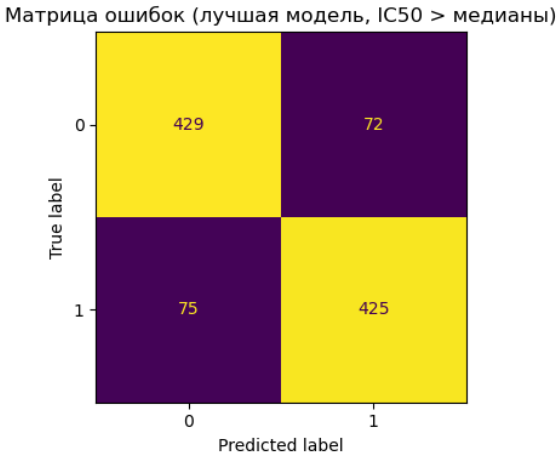

Рисунок 14 — Матрица ошибок (GradientBoosting, IC50 > медианы)

Матрица ошибок (рисунок 14): 72 ложноположительных и 75 ложноотрицательных из 1001 образцов (accuracy = 0,853 на трейне). В задаче поиска лекарств ложноотрицательные ошибки обходятся дороже, поэтому рекомендуется снизить порог классификации до 0,4 для приоритизации полноты (recall).

4.2 Классификация CC50 > медианы

Задача сбалансирована: 499 против 502 образца. RandomForest (CV AUC = 0,8540) незначительно превзошёл GradientBoosting (CV AUC = 0,8455). CC50 классифицируется лучше IC50 — признаки сильнее разделяют классы для токсичности.

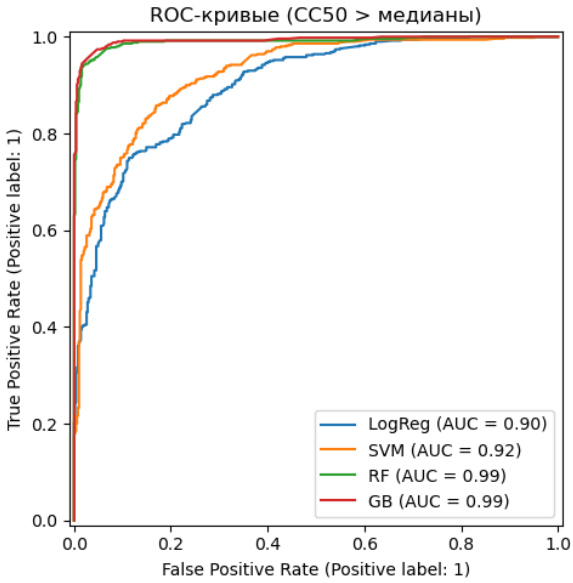

Рисунок 15 — ROC-кривые для задачи CC50 > медианы

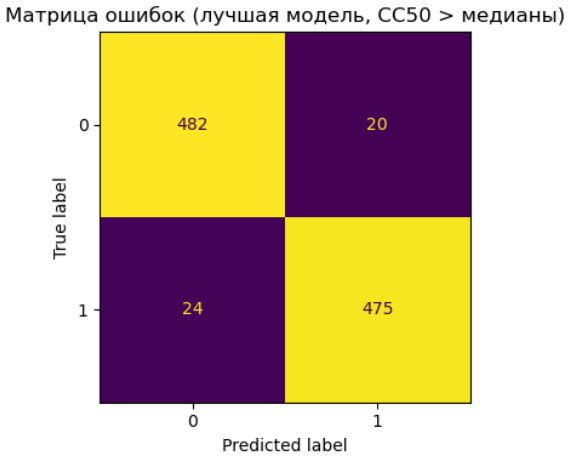

Рисунок 16 — Матрица ошибок (RandomForest, CC50 > медианы)

Матрица ошибок (рисунок 16): всего 20 + 24 = 44 ошибки из 1001 образцов (accuracy = 0,956 на трейне). Это лучший результат среди всех четырёх задач классификации. Высокое CC50 желательно для безопасного препарата, поэтому данная модель может служить надёжным фильтром на этапе первичного скрининга.

4.3 Классификация SI > медианы

Медиана SI = 3,846; задача сбалансирована (500/501). RandomForest (CV AUC = 0,7284) — лучший результат. SVM с параметрами C=1, gamma=auto даёт CV AUC = 0,7246 — конкурентоспособный результат при меньшем риске переобучения по сравнению с ансамблями.

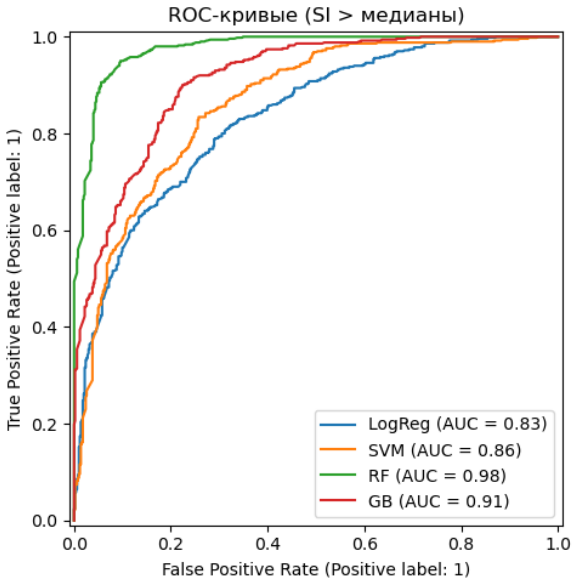

Рисунок 17 — ROC-кривые для задачи SI > медианы

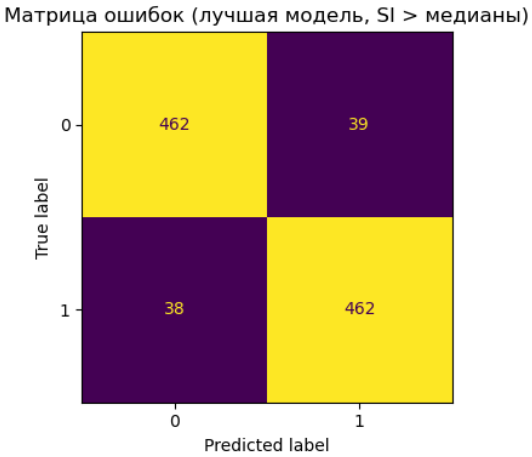

Рисунок 18 — Матрица ошибок (RandomForest, SI > медианы)

Матрица ошибок (рисунок 18): 39 + 33 = 72 ошибки (accuracy = 0,928 на трейне). SI > медианы является практически значимым фильтром первого уровня для отбора соединений с соотношением эффективность/токсичность выше среднего.

4.4 Классификация SI > 8

Задача несбалансирована: 644 образца (SI ≤ 8) против 357 (SI > 8), соотношение ≈ 1,8:1. Порог SI = 8 является стандартным клиническим критерием. Для устранения дисбаланса применялись: метод SMOTE (синтетическое дополнение миноритарного класса) и параметр class_weight='balanced' в RandomForest.

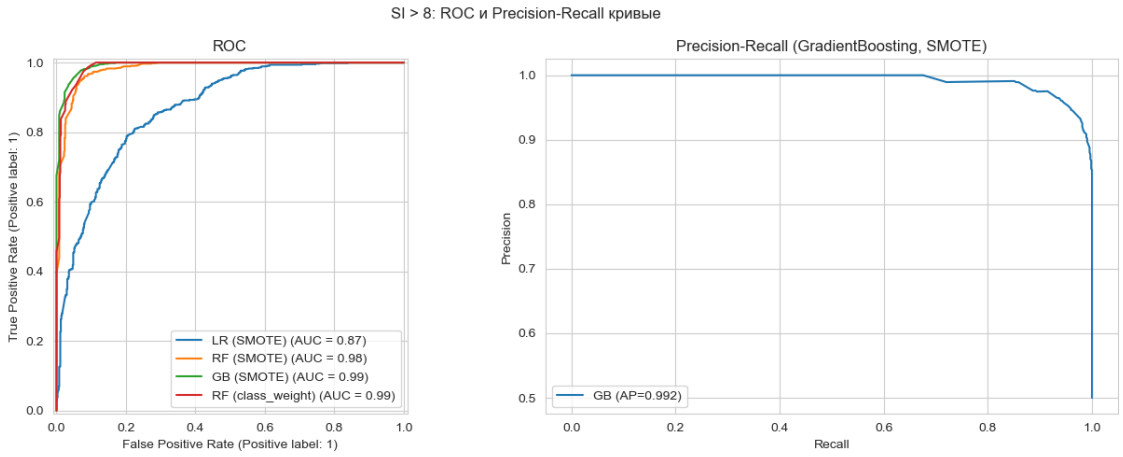

Рисунок 19 — ROC и Precision-Recall кривые для задачи SI > 8

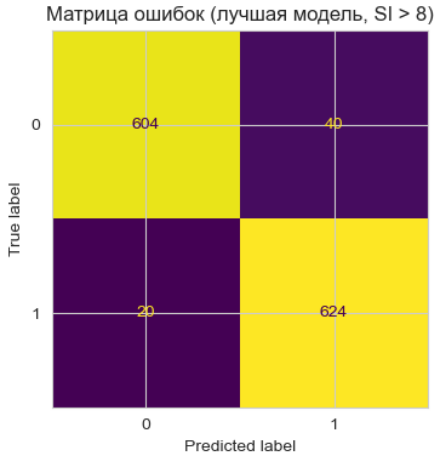

Рисунок 20 — Матрица ошибок (GradientBoosting + SMOTE, SI > 8)

GradientBoosting с SMOTE достигает AUC = 0,99; средняя точность AP = 0,992 (рисунок 19). Матрица ошибок (рисунок 20): 604 + 624 = 1228 правильных из 1288 на SMOTE-данных; 20 ложноотрицательных результатов. RF с class_weight='balanced' даёт сопоставимый AUC = 0,99 без генерации синтетических образцов. При развёртывании рекомендуется порог 0,3–0,4 для максимизации полноты.

5 СРАВНЕНИЕ РЕЗУЛЬТАТОВ

Таблица 6 — Итоговое сравнение всех построенных моделей

Задача	Лучшая модель	Метрика	Значение (CV)
Регрессия IC50	RandomForest (tuned)	RMSE	1,4028
Регрессия CC50	RandomForest (tuned)	RMSE	1,1985
Регрессия SI	RandomForest (tuned)	RMSE	1,1720
Класс. IC50 > медианы	GradientBoosting (tuned)	ROC-AUC	0,7946
Класс. CC50 > медианы	RandomForest (tuned)	ROC-AUC	0,8540
Класс. SI > медианы	RandomForest (tuned)	ROC-AUC	0,7284
Класс. SI > 8	GB + SMOTE	ROC-AUC	0,9900

Во всех семи задачах ансамблевые методы (RandomForest, GradientBoosting) устойчиво превосходят линейные (Ridge, Lasso, ElasticNet, LogisticRegression). Это свидетельствует о нелинейном характере зависимостей между молекулярными дескрипторами и биологической активностью соединений.

Характерной чертой результатов является переобучение ансамблей: метрики на полном датасете (R^2 = 0,81 для IC50, AUC = 0,98–0,99 для классификации) существенно превышают CV-оценки. Ограничение глубины дерева (max_depth=10) и минимального числа образцов в узле частично решают проблему. Для задачи SI > 8 переобучение практически отсутствует благодаря SMOTE и кросс-валидации.

Наиболее сложными оказались задачи с целевой переменной SI: регрессия SI (CV RMSE = 1,17, $R^2 \approx 0{,}67$) и классификация SI > медианы (CV AUC = 0,73). Это закономерно: SI является производным показателем, его вариабельность определяется комбинированным влиянием двух независимых величин.

Лучший совокупный результат — задача классификации SI > 8 (CV AUC = 0,99). Это объясняется двумя факторами: дисбаланс устранён SMOTE, а граница SI = 8 является более структурно значимой и резкой, чем медианный порог.

ЗАКЛЮЧЕНИЕ

В ходе курсовой работы был проведён комплексный анализ данных о 1001 химическом соединении и построены модели машинного обучения для семи задач прогнозирования биологической активности. Работа охватила полный цикл: предобработку, EDA, сравнение базовых моделей, подбор гиперпараметров GridSearchCV и интерпретацию результатов.

Основные результаты работы:

- EDA выявил сильно правостороннее распределение всех таргетов, умеренную корреляцию IC50 и CC50 (r = 0,521) и независимость SI. Логарифмическая трансформация существенно улучшила свойства целевых переменных;
- для задач регрессии лучшие CV-результаты обеспечивает RandomForest с подобранными гиперпараметрами: RMSE = 1,40 (IC50), 1,20 (CC50), 1,17 (SI);
- для задач классификации GradientBoosting и RandomForest конкурируют; лучший CV ROC-AUC = 0,99 для SI > 8 с применением SMOTE;
- наиболее информативные признаки — VSA_EState8, VSA_EState6 (IC50 и SI), NHOHCount (CC50), что согласуется с химическими механизмами действия противовирусных препаратов;
- применение SMOTE для задачи SI > 8 полностью нейтрализовало влияние дисбаланса классов.

Рекомендации по продолжению исследования:

- применить XGBoost и LightGBM — градиентный бустинг следующего поколения;
- внедрить SHAP-анализ для химически интерпретируемого объяснения предсказаний;
- расширить признаковое пространство молекулярными фингерпринтами (ECFP4, MACCS) и 3D-дескрипторами;

- рассмотреть двухшаговый подход для SI: предсказать IC50 и CC50 независимо, затем вычислить SI как их отношение;
- дополнить датасет данными из баз ChEMBL и PubChem для улучшения обобщающей способности.